

PROPUESTA TECNICA

Chatbot Hibrido con LLM para KitraDep

De un menu de opciones rigido
a un asistente conversacional inteligente

Documento tecnico, diseno, despliegue y presupuesto

Preparado por: Kira (asistente de Felipe Fierro)

Fecha: 18 de agosto de 2026

Version: 1.0

Indice

Seccion	Pag.
1. Resumen ejecutivo	3
2. Contexto del proyecto y estado actual	4
3. Que es un bot hibrido con LLM (conceptos)	6
4. Arquitectura tecnica propuesta	8
5. Los 6 componentes tecnicos en detalle	10
6. Comparativa de modelos LLM (Gemini vs alternativas)	14
7. Diseno del libreto y personalidad del bot (Kitra)	16
8. 'Entrenar' el LLM: prompt engineering + RAG (no es fine-tuning)	19
9. Guardrails, seguridad, etica y cumplimiento	21
10. Integracion con WhatsApp de la empresa	23
11. Despliegue, hosting y operacion 24/7	26
12. Plan de trabajo por fases y cronograma	28
13. COSTOS DETALLADOS: 1 mes, 3, 6 y 12 meses	30
14. Riesgos, mitigaciones y limites eticos	33
15. Checklist de arranque (que necesita Felipe)	35
16. Anexos: ejemplos, glosario, links utiles	36

1. Resumen ejecutivo

Que se propone. Evolucionar el chatbot actual de KitraDep (hoy una maquina de estados con menus numericos) hacia un asistente conversacional hibrido que combina inteligencia artificial generativa (LLM) para la conversacion natural, con un flujo controlado tradicional para las tareas criticas de agendamiento. El resultado se percibe humano, entiende texto libre, tolera desvios del guion, y responde con la personalidad y el conocimiento del negocio.

Por que. El bot actual es funcional pero rigido: solo entiende numeros o palabras exactas del menu, y al primer desvio conversacional 'se pierde'. Los usuarios esperan hablar con el bot como con una persona. Un bot hibrido resuelve ambos mundos: control total en lo critico (agendar cita, precios, datos personales) y conversacion natural en lo abierto (dudas, aclaraciones, saludos, preguntas espontaneas).

Como. Se reutiliza toda la base ya construida (motor Python, webapp FastAPI, guion YAML) y se le agregan seis piezas nuevas: (1) modelo LLM Gemini 2.0 Flash de Google, (2) base de conocimiento del negocio en formato documento, (3) system prompt con personalidad y limites, (4) router hibrido que decide cuando usar LLM vs flujo estricto, (5) memoria de conversacion, y (6) guardrails de seguridad y prevencion de alucinaciones.

Cuanto tarda. Aproximadamente 4 a 6 semanas de trabajo repartido para llegar a un bot funcional en WhatsApp real de la empresa, con la mayor parte del tiempo en disenio de contenido y testing, no en programacion.

Cuanto cuesta. El costo mensual operativo en produccion se estima entre **USD 10 y USD 30 mensuales** para un volumen tipico de una clinica pequena (100-300 conversaciones por dia). El grueso del costo no es el LLM (que puede ser incluso gratis con el free tier de Google), sino el hosting del servidor y eventual mensajes proactivos de recordatorio. Detalle completo en la seccion 13.

Que se necesita. Trabajo del equipo de KitraDep para: (a) validar personalidad y tono del bot, (b) proveer dumps de conversaciones reales para entrenar el prompt, (c) definir los limites eticos (que puede y que NO puede responder el bot, dado que es un rubro de salud), y (d) gestionar los tramites de Meta Business para el numero de WhatsApp oficial (unos dias a semanas segun agilidad de Meta).

Resumen en una frase: por menos de USD 30 al mes y en 4-6 semanas de trabajo, KitraDep puede tener un bot en WhatsApp que suena humano, agenda citas confiablemente y esta disponible 24/7.

2. Contexto del proyecto y estado actual

2.1 Que es KitraDep

Centro de kinesiología ubicado en Llano Subercaseaux 3791, oficinas 208-209, comuna de San Miguel, Santiago de Chile. Atiende de lunes a viernes de 8 a 21 horas y sabados de 9 a 13 horas. Cuenta con cuatro kinesiologos: Javiera Caceres y Jaime en horario AM, Francisco y Valentina en horario PM. Ofrece kinesiología individual 1-a-1 de 45-50 minutos, con distincion de precios segun prevision del paciente (FONASA / ISAPRE / Particular).

2.2 Problema actual

La atencion via WhatsApp la responden manualmente los kinesiologos en tiempos libres. Consecuencias observadas:

- Los mensajes fuera de horario laboral no se responden hasta el dia siguiente, con perdida de leads.
- Preguntas repetitivas (precios, horarios, direccion, previsiones aceptadas) consumen tiempo valioso.
- El proceso de agendamiento requiere multiples intercambios manuales.
- No hay registro centralizado de conversaciones para analizar patrones.
- Escalar a mas horas de atencion implica contratar personal administrativo.

2.3 Que se construyo hasta ahora (fases 1, 2 y 4-A)

Se implemento un chatbot funcional en tres iteraciones:

- Fase 1 - Guion:** archivo YAML con 21 estados y logica bifurcada FONASA/ISAPRE/Particular, extraida de casos reales.
- Fase 2 - Motor CLI:** interprete Python que lee el YAML y permite conversar en terminal. Sin dependencias mas alla de PyYAML.
- Fase 4-A - Simulador web:** webapp con FastAPI + HTMX + Tailwind, interfaz identica a WhatsApp, sesiones multiples, corre local sin costo.

Todo esto vive en la carpeta chatbot/ del repositorio, con commits limpios y documentacion completa (MOTOR.md, WEBAPP.md, DIAGNOSTICO.md, entre otros).

2.4 Limitacion clave que se busca resolver

El bot actual es una **maquina de estados pura**: opera en base a menus numericos y palabras clave exactas. Sus limitaciones son estructurales del enfoque, no bugs:

Comportamiento	Bot actual	Bot deseado
Usuario escribe '1' o palabra exacta	Funciona	Funciona
Usuario escribe frase libre	Se pierde	Entiende
Pregunta fuera del guion	Responde 'no entendi'	Responde con contexto
Recuerda mensajes previos	No	Si

Comportamiento	Bot actual	Bot deseado
Tono conversacional	Robotico, listas y numeros	Natural, empatico
Maneja typos	No	Si
Sinonimos y jerga	No	Si

El objetivo NO es tirar el bot actual a la basura. Se REUSA todo lo construido. El LLM se agrega ENCIMA como una capa adicional que hace al bot conversacional, mientras que el flujo de estados sigue manejando las tareas criticas donde se necesita control absoluto (agendar, cobrar, tomar datos).

3. Que es un bot hibrido con LLM (conceptos)

3.1 Los tres tipos de bot que existen

Antes de justificar el enfoque hibrido, conviene ubicar donde se para cada tecnologia:

Tipo	Como decide	Pros	Contras
Maquina de estados	Menus + palabras exactas	Control total, cero costo, cero alucinacion	Rigido, robotico, se pierde con texto libre
LLM puro	El modelo genera todo	Se siente humano, entiende cualquier cosa	Puede inventar datos, sin garantia de flujo, cuesta tokens
Hibrido	Router: flujo para lo critico, LLM para lo libre	Lo mejor de ambos mundos	Mas complejo de construir y afinar

3.2 El truco: no todo va al LLM

El error mas comun al hacer un bot 'inteligente' es mandar TODO al LLM. Suena tentador porque es la parte magica, pero rompe el bot en las tareas criticas. Ejemplo:

Escenario: el usuario dice 'quiero agendar para el martes a las 3 con Javiera'. Un LLM puro podria confirmar la cita alegremente, aunque Javiera no atienda los martes, aunque las 3 PM no exista en la agenda, o aunque el paciente no haya dado su nombre ni telefono. Un flujo controlado nunca cometeria ese error.

La solucion hibrida:

● **Conversacion libre, dudas, FAQ, saludos, aclaraciones** -> LLM (natural y flexible).

● **Recolectar datos criticos, cerrar agenda, confirmar precios** -> Flujo controlado (preciso y auditable).

● **El router** es la pieza que decide en cada turno cual usar.

3.3 Analogia util


Pensalo asi: el bot hibrido es como un vendedor amable en un mostrador. Charla contigo sobre el clima, te explica los productos, responde tus dudas raras (LLM). Pero cuando llega el momento de cobrar tu tarjeta, saca el POS (flujo controlado) y sigue los pasos exactos del checkout: no improvisa el numero de tarjeta, no 'redondea' el precio, no salta pasos.

Esa disciplina es la que hace confiable el enfoque hibrido en un negocio real, especialmente en un rubro sensible como salud.

4. Arquitectura tecnica propuesta

4.1 Vista general

La siguiente figura muestra el flujo de datos desde el mensaje del paciente hasta la respuesta del bot y la notificacion al equipo:



4.2 Que se reutiliza del bot actual

El diseno respeta lo ya construido y solo agrega capas encima. Concretamente:

Componente actual	Rol en el nuevo bot
motor_core.py	Sigue siendo el motor de la maquina de estados (tareas criticas).
guion.yaml	Sigue definiendo el flujo de agendamiento paso a paso.
webapp.py + templates	Se transforma en la interfaz de pruebas y demos internas (opcional).

Componente actual	Rol en el nuevo bot
MOTOR.md, WEBAPP.md, casos_reales.md	Documentacion base que alimenta el system prompt del LLM.

4.3 Que se agrega nuevo

- **Modulo LLM** (nuevo archivo `llm_client.py`): cliente que habla con Gemini API.
- **Router hibrido** (`router.py`): logica de decision flujo vs LLM en cada turno.
- **Base de conocimiento** (`knowledge/* .md`): documento fuente que el LLM lee.
- **System prompt** (`prompts/kitra.txt`): personalidad, tono, limites, ejemplos.
- **Memoria de conversacion**: buffer de N ultimos turnos + resumen comprimido si excede.
- **Guardrails** (`guardrails.py`): filtros de tema, PII, deteccion de handoff a humano.
- **Webhook WhatsApp** (`whatsapp_webhook.py`): endpoints para Meta Cloud API o Twilio.
- **Persistencia** (SQLite inicial, Postgres si escala): conversaciones, agendamientos, logs de LLM.
- **Notificaciones al staff**: email o WhatsApp interno cuando se cierra un agendamiento o el bot deriva a humano.

5. Los 6 componentes tecnicos en detalle

Esta seccion desarrolla cada pieza del bot hibrido, con foco en el 'como' y las decisiones de disenio. La lectura es densa pero es el corazon tecnico de la propuesta; puede saltarse en una primera lectura y volver luego.

5.1 El LLM (cerebro que redacta las respuestas)

Que hace: recibe en cada turno el system prompt, la base de conocimiento relevante y los ultimos mensajes de la conversacion. Devuelve una respuesta en lenguaje natural.

Modelo elegido: Google Gemini 2.0 Flash (razones detalladas en seccion 6). Tres motivos rapidos:

- **Free tier** real y utilizable: hasta ~1500 requests por dia gratis para desarrollo.

- **Costo** pagado ridiculamente bajo: USD 0.075 por millon de tokens de entrada, USD 0.30 por millon de salida.

- **Latencia** baja (~0.8-1.5 segundos) que se disimula bien con el 'escribiendo...' del chat.

Implementacion: el SDK oficial de Google se llama `google-generativeai` y se instala con `uv pip install google-generativeai`. La llamada minima es de 5 lineas. El modulo se encapsula en `llm_client.py` con `retry`, `timeout` y `fallback` a mensaje generico si el API cae.

Alternativa gratis 100%: Ollama local con Llama 3.1 8B. Requiere un PC con 16GB de RAM. Se usa como fallback offline o si hay que garantizar privacidad total sin salida a internet.

5.2 Base de conocimiento (lo que el bot 'sabe' de KitraDep)

Que es: uno o varios archivos de texto (Markdown) con TODO lo que el bot puede necesitar responder. Es el 'libro de texto' que se le pasa al LLM en cada request como contexto.

Estructura propuesta:

```
knowledge/ 01_servicios.md # que se ofrece, duracion, evaluacion inicial, sesion
tipica 02_precios.md # tabla completa por prevision + reglas legales FONASA
03_horarios.md # horarios, kines por turno, sabados 04_ubicacion.md # direccion, como
llegar, estacionamiento, transporte publico 05_previsiones.md # FONASA (no adherido,
valor preferencial), ISAPRE, particular 06_agendamiento.md # como es el proceso,
orden medica, boletas, reembolso 07_faq.md # preguntas frecuentes reales de WhatsApp
08_politicas.md # cancelaciones, atrasos, primera sesion, pagos 09_equipo.md #
nombres, especialidades, horarios de cada kine 10_limites.md # temas donde el bot NO
opina (diagnostico, tratamiento)
```

Fuente: se destila de `chatbot/flujo/casos_reales.md` ya existente, mas dumps de conversaciones reales de WhatsApp que aportara el equipo de KitraDep. Total estimado: 3000-5000 palabras (~15-25 KB de texto). Perfectamente manejable como contexto del LLM en cada request.

Actualizacion: cambiar informacion (nuevo precio, nuevo kine, nuevo horario) es editar un archivo Markdown y reiniciar el servidor. No se toca codigo Python. Esto es una ventaja enorme del disenio.

5.3 System prompt (personalidad + limites)

Que es: el mensaje 'invisible' que se le manda al LLM antes de cualquier interaccion del usuario. Define quien es el bot, como habla, que puede y que no puede hacer. Es donde vive el 80% de la calidad

percibida del bot.

Estructura típica del prompt:

- 1 **Identidad:** 'Sos Kitra, la asistente virtual de KitraDep, un centro de kinesiología en San Miguel, Santiago de Chile'.
- 2 **Personalidad:** 'Tono cercano, chileno neutro (evitar chilenismos muy marcados), empático, profesional. Trata de usted por defecto, tutea si el usuario tutea primero'.
- 3 **Alcance:** 'Solo respondes sobre KitraDep. Si te preguntan otra cosa (política, deportes, otros negocios), decis amablemente que no puedes ayudar con eso'.
- 4 **Anti-alucinación:** 'Si no sabes algo con certeza, decilo. NUNCA inventes precios, horarios, nombres de kinesiólogos ni fechas'.
- 5 **Handoff:** 'Si el paciente pide hablar con una persona, tiene una duda médica compleja, o el tema es delicado, deriva al WhatsApp de la kine derivadora que se te indique'.
- 6 **Formato:** 'Respuestas cortas (2-4 líneas), usa *negrita* para lo importante, no uses emojis excesivos (máximo 1 por respuesta)'.
- 7 **Ejemplos:** 3-5 conversaciones ideales que muestran el estilo esperado.

Longitud típica: 100-200 líneas. Es un archivo de texto plano que se itera decenas de veces hasta que el bot 'suena' como uno quiere. Ese trabajo iterativo es el arte del prompt engineering (sección 8).

5.4 El router híbrido (decide flujo vs LLM)

Que es: la pieza más crítica del diseño híbrido. En cada mensaje del usuario, decide si atiende el motor de estados o el LLM.

Reglas propuestas (en orden de prioridad):

- 1 Si el usuario está en medio de una tarea crítica ya iniciada (ej. dio nombre, está ingresando teléfono) -> **flujo controlado** continua.
- 2 Si el LLM detecta intención de agendar en la conversación libre -> **transfiere** al flujo controlado (que empieza a pedir datos ordenadamente).
- 3 Si el usuario escribe un comando global (menu, cancelar, hablar con humano) -> **manejo especial**.
- 4 En cualquier otro caso (dudas, FAQ, saludos, aclaraciones) -> **LLM** responde con contexto.

Implementación: ~150 líneas de Python en `router.py`. La detección de intención 'quiere agendar' la hace el propio LLM devolviendo una etiqueta estructurada en su respuesta (técnica conocida como 'function calling' o 'tool use').

5.5 Memoria de conversación

Problema: el LLM es amnésico. Cada llamada al API es independiente. Si no le pasas los mensajes previos, no recuerda de que estaban hablando.

Solución en 3 capas:

Buffer corto: se guardan y reenvían los últimos 10 turnos (usuario + bot) en cada request. Cubre 95% de las conversaciones típicas.

Resumen comprimido: si la charla supera 10 turnos, el LLM resume los turnos mas viejos en 2-3 lineas ('el paciente pregunto por precios FONASA, se le explico...') y se reemplazan los originales por el resumen.

Persistencia: todo se guarda en SQLite ('conversaciones' table) para poder auditar y mejorar el bot despues.

Impacto en costo: los tokens de historial se cobran como input. Un turno tipico consume ~500-1000 tokens de contexto. Con Gemini Flash a USD 0.075/M eso son 0.00005-0.0001 dolares por turno. Practicamente nada para volumenes chicos.

5.6 Guardrails de seguridad y prevencion de alucinaciones

Que son: capas de proteccion que evitan que el bot se salga del carril. Se implementan en varios puntos:

Guardrail	Como funciona
Filtro de temas	Regex + LLM chequean si el mensaje sale del dominio KitraDep.
Filtro de PII	No se logea RUT/telefono/email en claro. Se hashean o enmascaran.
Anti-alucinacion	Instrucciones estrictas + verificacion post-respuesta con base de conocimiento.
Rate limiting	Max N mensajes por numero por hora, para evitar abuso o costo runaway.
Deteccion medica	Si el mensaje es una consulta medica clara -> handoff automatico a humano.
Deteccion emergencia	Palabras clave de urgencia (dolor severo, no puedo caminar) -> derivacion inmediata a telefono de emergencia.

Impacto operativo: cada guardrail agrega latencia y complejidad. Se implementan por orden de importancia. El critico es el de deteccion medica: en un rubro de salud, un bot que diagnostica es un riesgo legal serio.

6. Comparativa de modelos LLM (Gemini vs alternativas)

6.1 Modelos evaluados

Se consideran cinco alternativas viables para un bot de este tamaño. La elección NO es solo técnica: influye el costo, la latencia, la privacidad, y la facilidad de cambio si algo sale mal.

Modelo	USD in / 1M tok	USD out / 1M tok	Latencia	Free tier	Calidad
Gemini 2.0 Flash (Google)	0.075	0.30	~1.0s	Si (generoso)	Muy alta
GPT-4o-mini (OpenAI)	0.15	0.60	~1.2s	No	Muy alta
Claude Haiku 3.5 (Anthropic)	0.80	4.00	~1.5s	No	Muy alta
GPT-4o (OpenAI, top)	2.50	10.00	~1.5s	No	Excelente
Llama 3.1 8B (Ollama local)	0	0	2-5s CPU	Gratis (auto-host)	Media-alta

6.2 Por que Gemini 2.0 Flash para KitraDep

- Costo:** el mas barato de los oficiales por un margen amplio (~50% mas barato que GPT-4o-mini, 10x mas barato que Claude Haiku).
- Free tier real:** hasta 1500 requests por dia sin pagar. Suficiente para todo el desarrollo y las primeras semanas de produccion de un negocio chico.
- Calidad:** para tareas de conversacion en espanol con contexto acotado, esta al nivel de GPT-4o-mini.
- Cambio de modelo trivial:** encapsulamos el LLM detras de una interfaz. Si Gemini decepciona, migrar a GPT-4o-mini o Claude es cambiar 20 lineas.

6.3 Cuando reconsiderar la eleccion

Escenario	Modelo recomendado
Bot muy complejo con razonamiento medico avanzado	Claude Sonnet o GPT-4o
Volumen enorme (>10k conversaciones/dia) y costo crucial	Gemini Flash o Llama 3.1 self-hosted
Privacidad total obligatoria (sin salida a internet)	Llama 3.1 con Ollama en servidor propio
Necesidad de function calling avanzado y tools	GPT-4o-mini (mejor documentacion de tools)
Si el proyecto migra a Walmart	OBLIGATORIO: AI Innovation Lab / AI Launchpad interno

6.4 Estrategia de portabilidad

El diseño del módulo `llm_client.py` abstrae el proveedor detrás de una función `generar_respuesta(system_prompt, historial, mensaje) -> str`. Cualquier cambio de proveedor futuro no toca la lógica del router ni de los guardrails. Esto es una aplicación del principio de **dependency inversion** (la 'D' de SOLID): dependemos de una abstracción, no de una implementación concreta.

7. Diseno del libreto y personalidad del bot (Kitra)

7.1 Nombre y presentacion

Nombre propuesto: *Kitra*. Es un guino a KitraDep pero con identidad propia. Suena femenino, corto, facil de recordar. Alternativas: Kitri, Kina, Kit, o simplemente 'Asistente de KitraDep' si prefieren neutralidad.

Primera impresion (mensaje de bienvenida):

'Hola! Soy Kitra, la asistente virtual de KitraDep. Puedo ayudarte con informacion, agendar tu sesion o resolver dudas sobre nuestros servicios de kinesiologia. En que te puedo ayudar hoy?'

Justificacion: nombre + rol + capacidades + pregunta abierta (no menu numerico). En 4 lineas el usuario sabe con quien habla, que puede pedir, y tiene libertad para escribir cualquier cosa.

7.2 Tono y personalidad

Dimension	Definicion propuesta
Formalidad	Trata de USTED por defecto. Tutea si el usuario tutea primero.
Registro	Espanol chileno neutro. Sin modismos muy marcados ('cachai', 'weon', 'po').
Longitud	Respuestas cortas (2-4 lineas). Si es tecnico, usa listas.
Emojis	Uso moderado. Maximo 1 por mensaje. Priorizar utilidad sobre decoracion.
Empatia	Reconoce el motivo de la consulta antes de responder ('Entiendo, buscas...').
Ritmo	No manda 5 mensajes seguidos. 1 respuesta = 1 burbuja WhatsApp.
Errores	Si no entiende, pide aclaracion suavemente. Nunca dice 'no comprendo'.

7.3 Ejemplos de conversaciones deseadas vs no deseadas

Ejemplo 1 - Pregunta libre sobre precios:

Usuario: hola cuanto sale la kine? tengo isapre banmedica

Bot ACTUAL (menu rigido): No entendi. Escribe 1) Servicios, 2) Precios, 3) Agendar.

Bot HIBRIDO (Kitra): Hola! Buenisimo que tengas ISAPRE. Con nosotros el valor por sesion es de \$25.000. Tambien tenemos packs con descuento: 5 sesiones a \$115.000 o 10 sesiones a \$230.000. Te dejo boleta para reembolso en tu ISAPRE. Queres que te agende una primera evaluacion?

Ejemplo 2 - Pregunta fuera del guion pero relacionada:

Usuario: tienen estacionamiento en el edificio?

Bot ACTUAL: No entendi. Escribe menu para volver al inicio.

Bot HIBRIDO: El edificio no tiene estacionamiento propio, pero hay estacionamiento publico a media cuadra y varias lineas de micro llegan a Llano Subercaseaux. Si vienes en metro, la estacion mas cercana es San Miguel (Linea 2). Necesitas la direccion exacta?

Ejemplo 3 - Pregunta medica (debe derivar):

Usuario: me duele mucho la rodilla al bajar escaleras, sera menisco?

Bot ACTUAL: No entendi.

Bot HIBRIDO (con guardrail medico): Entiendo tu preocupacion. No puedo darte un diagnostico por chat, pero es exactamente el tipo de consulta que nuestro equipo puede evaluar en la primera sesion (que incluye evaluacion completa). Queres que te agende con una kinesiologa? Si el dolor es severo o repentino, te sugiero consultar tambien con un traumatologo.

7.4 Que se necesita del equipo KitraDep para el libreto

Validar nombre y tono (30 min de reunion con quien defina la marca).

Dumps de conversaciones reales: 20-30 chats completos de WhatsApp reciente (con datos personales borrados). Fuente de oro para calibrar el prompt.

Lista de 'nunca': cosas que el bot JAMAS debe decir (diagnosticos, promesas de sanacion, precios que no existen).

Handoff: numero de WhatsApp o email donde deriva cuando el bot no puede. Horarios en que ese contacto responde.

FAQ ampliada: agregar preguntas que hoy respondes a mano y no estan en el guion actual.

8. 'Entrenar' el LLM: prompt engineering + RAG (no es fine-tuning)

Aclaracion importante: cuando la gente dice 'entrenar el LLM' para un chatbot, en el 99% de los casos NO se refiere a fine-tuning real del modelo (que es caro, complejo y raramente necesario). Se refiere a prompt engineering + RAG, que es lo que aca proponemos y explicamos.

8.1 Las tres formas de 'enseñarle' cosas a un LLM

Metodo	Que es	Cuando conviene
Prompt engineering	Ajustar el system prompt para dar instrucciones detalladas.	SIEMPRE. Es la base.
RAG (Retrieval-Augmented Generation)	Buscar fragmentos relevantes de la base de conocimiento y agregarlos al contexto en cada request.	Cuando la info es grande (>10K palabras).
Fine-tuning	Reentrenar los pesos del modelo con miles de ejemplos etiquetados.	Muy raramente. Costoso y complejo.

Para KitraDep: **prompt engineering + un RAG minimalista** son mas que suficientes. Fine-tuning se descarta.

8.2 Como funciona el prompt engineering en la practica

Es un proceso iterativo, no un evento. Ciclo tipico:

- 1 Se escribe un prompt v1 basado en la personalidad definida.
- 2 Se corren 20-30 conversaciones de prueba (algunas de dumps reales, algunas inventadas malintencionadamente).
- 3 Se identifican fallos: 'aca invento un precio', 'aca no derivo cuando debia', 'aca respondio demasiado largo'.
- 4 Se ajusta el prompt: se agregan reglas, ejemplos negativos, aclaraciones.
- 5 Se re-testea. Se documentan las mejoras.
- 6 Se repite hasta que el bot pase un conjunto de test predefinido (~50 casos).

Herramienta clave: el **test suite de conversaciones**. Un archivo YAML con casos {input, resultado_esperado}. Se corre automatico despues de cada cambio de prompt. Es la salvaguarda contra romper algo al mejorar otra cosa (regresiones).

8.3 Que es RAG y por que probablemente lo necesitemos

Retrieval-Augmented Generation: en vez de meter TODA la base de conocimiento en cada request (caro y a veces excede el limite del modelo), primero se hace una busqueda de los fragmentos MAS relevantes al mensaje del usuario, y solo esos se agregan al contexto.

Ejemplo concreto: usuario pregunta 'que documentos necesito para reembolso ISAPRE?'. RAG busca en la base de conocimiento los fragmentos con palabras 'reembolso', 'ISAPRE', 'boleta', 'documento'. Solo esos 2-3 parrafos se pasan al LLM, no el documento completo.

Implementacion minima: con la libreria chromadb (base vectorial gratis y embebida) + embeddings de Google (gratis en el free tier). Total: ~100 lineas de codigo. NO requiere GPU.

Cuando saltar RAG: si la base de conocimiento total pesa menos de ~5000 palabras (~20 KB de texto), directamente se puede meter completa en el contexto. Gemini Flash acepta 1M de tokens de contexto: sobra espacio. Para KitraDep, tal vez arranquemos SIN RAG y lo agreguemos si crece.

8.4 Estrategia de mejora continua

Una vez en produccion, el bot mejora con estos loops:

- bullet **Log de conversaciones:** se guardan todas para poder revisar.
- bullet **Revision semanal:** quien opere el bot lee 10-20 conversaciones aleatorias por semana.
- bullet **Feedback explicito:** al final de la conversacion se puede pedir un thumbs up/down.
- bullet **Alertas:** si el bot deriva a humano, si dice 'no se', si el usuario se enoja (palabras clave) -> notificacion al equipo.
- bullet **A/B testing de prompts:** cambio de prompt se prueba en 10% de conversaciones antes de roleear al 100%.

9. Guardrails, seguridad, etica y cumplimiento

9.1 Por que este capitulo es mas largo que los demas

KitraDep opera en el rubro salud. Un bot que da consejo medico erroneo, diagnostica sin licencia, o promete resultados terapeuticos es un problema legal serio. Ademas, se manejan datos personales sensibles (RUT, telefono, condicion medica implicita). Este capitulo aborda como el diseno se protege contra esos riesgos.

9.2 Riesgos identificados y mitigaciones

Riesgo	Mitigacion
Bot inventa precios o horarios	Base de conocimiento como fuente unica + instrucciones estrictas + fallback: 'no tengo esa info, te derivo'.
Bot diagnostica una lesion	Guardrail medico: detecta consulta clinica -> respuesta canned + handoff obligatorio.
Bot promete cura o resultado	Prompt prohíbe explicitamente. Test suite valida frases prohibidas.
Fuga de datos personales	Sesiones aisladas por numero. RUT/telefono nunca en logs claros. HTTPS obligatorio.
Bot atacado con prompts maliciosos	Filtro de tema + jailbreak detection + rate limiting por numero.
Costo runaway por abuso	Rate limiting + circuit breaker: si un numero gasta > USD 1 en un dia se pausa.
Bot cae y nadie se entera	Healthcheck + alertas por email al admin + fallback a mensaje 'estamos con problemas tecnicos'.

9.3 Cumplimiento legal (Chile)

- Ley 19.628 sobre proteccion de datos personales:** requiere consentimiento, finalidad especifica, y derecho de rectificacion. Se implementa con un mensaje de consentimiento en la primera interaccion.
- Ley 20.584 sobre derechos y deberes del paciente:** el bot NO puede sustituir consulta profesional. Debe declararlo explicitamente cuando corresponda.
- Nueva Ley 21.719 (2024, en vigencia progresiva 2026):** normativa reforzada de datos personales. Se recomienda revisar con abogado antes de produccion.
- Retencion de datos:** definir cuanto tiempo se guardan las conversaciones (recomendado: 90 dias, salvo agendamientos confirmados).

9.4 Declaraciones minimas obligatorias en el bot

- Al inicio de la conversacion (mensaje de bienvenida) o en pie de primer intercambio, deben aparecer:
- Aviso de que es un asistente automatizado (no una persona real).**

bullet Aviso de que las conversaciones pueden ser revisadas para mejorar el servicio.

bullet Aviso de que la informacion NO reemplaza consulta profesional.

bullet Enlace a la politica de privacidad (URL, aunque sea una pagina simple).

bullet Numero o contacto de emergencia real para casos urgentes.

9.5 Handoff a humano: cuando y como

El bot deriva a una persona real en los siguientes casos, siempre:

- 1 Usuario lo pide explicitamente ('quiero hablar con alguien', 'una persona por favor').
- 2 El bot detecta consulta medica compleja (diagnostico, tratamiento, medicamento).
- 3 Palabras clave de urgencia (dolor severo, no puedo caminar, accidente).
- 4 Reclamo o queja formal ('estoy molesto', 'quiero devolucion', 'voy a reclamar').
- 5 El bot no supo responder despues de 2 intentos en el mismo tema.
- 6 Usuario que ya agendo, tiene una duda especifica sobre SU cita concreta.

El handoff es una respuesta clara: *'Voy a derivarte con nuestra kine derivadora, Javiera. Te va a escribir por este mismo WhatsApp en un rato (o al +56 9 XXXX XXXX). Mientras tanto, hay algo mas en lo que te pueda ayudar?'*

10. Integracion con WhatsApp de la empresa

10.1 Los 3 caminos posibles

Camino	Setup	Costo mensual	Riesgo	Recomendacion
Meta Cloud API (oficial)	1-3 semanas de tramites	USD 0 (mensajes de servicio son gratis)	Bajo	PRODUCCION
Twilio for WhatsApp (reventa)	1 dia	USD 1-5 fijo + centavos por mensaje	Bajo	PROTOTIPO
whatsapp-web.js (no oficial)	1 hora	USD 0	ALTO: baneo del numero	NO USAR EN PRODUCCION

10.2 Plan recomendado: Twilio Sandbox para desarrollo -> Meta Cloud API para produccion

Fase de desarrollo (semanas 2-4): Twilio Sandbox. Es gratis, se activa en 15 minutos, permite probar con tu propio WhatsApp personal. Limitacion: cada persona que quiera probarlo debe enviar un codigo de union primero. Perfecto para pruebas internas.

Fase de produccion (semanas 5-6+): Meta Cloud API. Requiere tramites pero es la unica opcion escalable y sin costo por mensaje de servicio.

10.3 Requisitos concretos para Meta Cloud API

- 1 **Cuenta Meta Business:** crearla en `business.facebook.com`. Gratis, 30 minutos.
- 2 **Verificacion del negocio:** Meta pide documentacion (RUT de la empresa, direccion, sitio web, factura de servicios). Tarda 3-14 dias habiles.
- 3 **Numero de telefono dedicado:** NO puede ser el WhatsApp personal actual del centro. Se puede portar el numero actual si se libera del app de WhatsApp normal (proceso irreversible), o comprar un numero nuevo.
- 4 **Display name aprobado:** Meta revisa el nombre que aparecera al chatear con el bot (ej. 'KitraDep - Kinesiologia'). Tarda 1-3 dias.
- 5 **App de Meta for Developers:** se crea una app tipo 'WhatsApp' que expone el API token. Gratis.
- 6 **Webhook publico HTTPS:** el servidor donde corre el bot debe estar expuesto a internet con SSL valido. Se resuelve con VPS + Let's Encrypt (gratis).
- 7 **Plantillas de mensajes (templates):** si se envian mensajes proactivos (recordatorios), cada template debe ser aprobado por Meta. Los mensajes de respuesta a chats iniciados por el usuario NO requieren template.

10.4 Que pasa dentro de la integracion tecnica

Flujo entrante (paciente escribe al bot):

1. Paciente escribe al numero de WhatsApp del centro. 2. Meta Cloud API envia un POST a nuestro webhook: `https://kitradep.tudominio.cl/webhook` 3. Webhook FastAPI recibe el

mensaje, extrae numero + texto. 4. Se recupera la sesion del usuario (SQLite), se agrega el mensaje al historial. 5. Router decide: flujo controlado o LLM. 6. Se genera la respuesta. 7. Se envia respuesta via POST a Meta Cloud API. 8. Meta la entrega en el WhatsApp del paciente. 9. Se guarda la conversacion en BD.

Latencia total esperada: 1.5 a 3 segundos (99% de eso es el LLM).

10.5 Numero de telefono: opciones concretas

- **Opcion A - Numero nuevo:** comprar una linea prepago o SIM dedicada (~CLP 5000 setup, ~CLP 2000/mes minimo). Independiente del numero actual del centro.
- **Opcion B - Portar el numero actual:** el numero de WhatsApp que hoy usa el centro se desconecta del WhatsApp normal y se conecta al bot. Riesgo: se pierden todos los chats historicos y grupos. Recomendable solo si quieren consolidar.
- **Opcion C - Segundo numero del mismo dueño:** muchos celulares permiten dual SIM o eSIM. Se agrega una linea nueva al celu personal del director, dedicada al bot. Practico y barato.

10.6 Mensajes proactivos (recordatorios de cita)

Aparte de responder, el bot puede iniciar conversaciones. Ejemplo: recordatorio 24 horas antes de la sesion, o solicitud de feedback 1 hora despues. Consideraciones:

- Cada mensaje proactivo debe usar un **template aprobado** por Meta.
- Costo por mensaje: ~USD 0.05-0.07 (Chile, categoria 'Utility').
- Si el paciente responde al recordatorio, se abre una 'ventana de servicio' de 24h en la que se puede seguir respondiendo gratis.
- Recomendacion: implementar recordatorios en Fase 4 (opcional), despues de que el bot este estable en produccion.

11. Despliegue, hosting y operacion 24/7

11.1 Opciones de hosting

Opcion	Costo/mes	Ventajas	Desventajas
PC personal + ngrok	USD 0	Cero setup, ideal para desarrollo	Se cae si apagas el PC. NO produccion.
Hetzner CX11 (VPS)	USD 4.60	Barato, potente, buena reputacion	Requiere setup Linux basico
DigitalOcean Basic Droplet	USD 6.00	Interfaz amigable, docs excelentes	Un pelo mas caro
Railway.app	USD 5-10	Deploy con un click desde Git	Se puede disparar con trafico
Fly.io	USD 0-5 (free tier)	Deploy simple, escala automatico	Free tier limitado
AWS/GCP/Azure	USD 20-50+	Escala infinito, features avanzadas	Overkill para el volumen

Recomendacion: Hetzner CX11 (USD 4.60/mes) para produccion. Excelente relacion precio/potencia, ubicacion europea (latencia OK a Chile), stack Ubuntu estandar.

11.2 Stack de servidor propuesto

Sistema operativo: Ubuntu 24.04 LTS Runtime: Python 3.12 con uv Web server: Uvicorn (dev) + Gunicorn (prod) Reverse proxy: Caddy (o nginx) con SSL automatico Let's Encrypt BD inicial: SQLite (archivo en disco) BD si escala: PostgreSQL 16 Proceso manager: systemd (nativo Linux) Logs: journalctl + archivo rotado en disco Backups: script cron diario a S3-compatible (Backblaze B2, USD 6/TB) Monitoreo: UptimeRobot (free tier) + Sentry (free tier)

11.3 CI/CD y deploy

Repositorio Git privado (GitHual, gratis).

Deploy automatico: push a rama main -> GitHub Actions ejecuta tests -> si pasan, se conecta por SSH al servidor y hace pull + restart del servicio.

Rollback: git revert + push. En 2 minutos vuelve a la version anterior.

Environments: staging (para probar cambios) + production. Ambos en el mismo VPS con puertos distintos, o dos VPS baratos.

11.4 Backups y disaster recovery

Datos criticos: BD SQLite (conversaciones, agendamientos, sesiones), base de conocimiento (git), configuracion (.env cifrado).

Frecuencia: BD se backupea diariamente a las 3 AM Chile. Retencion 30 dias.

Ubicacion: Backblaze B2 (USD 0.006/GB/mes) o Google Drive (15 GB gratis).

Restauracion: documentada en RUNBOOK.md, testada trimestralmente.

11.5 Monitoreo y alertas

- **UptimeRobot:** pinga /health cada 5 minutos. Alerta por email si cae.
- **Sentry:** captura errores no manejados con stack trace. Notifica al admin.
- **Metricas custom:** requests/min, latencia LLM, costo diario acumulado. Dashboard simple con Grafana o incluso un flat HTML.
- **Alertas de negocio:** mas de 5 handoffs por hora, o costo LLM > USD 1/dia -> email.

12. Plan de trabajo por fases y cronograma

Timeline realista de 6 semanas asumiendo dedicacion parcial de Felipe (~10 hrs/semana) y trabajo asincronico con la asistente IA (Kira/Code Puppy) para la programacion:

12.1 Fase A - Bot hibrido en simulador local (Semana 1)

Objetivo: Kitra funcionando en la webapp local con LLM. Aun no toca WhatsApp real.

- Sacar API key de Gemini (Felipe, 5 min).
- Instalar SDK google-generativeai (Kira, 10 min).
- Programar llm_client.py con retry/timeout (Kira, 2 hrs).
- Programar router hibrido primera version (Kira, 3 hrs).
- Escribir system prompt v1 basado en casos_reales.md (Kira, 2 hrs).
- Convertir guion.yaml a base de conocimiento en Markdown (Kira, 2 hrs).
- Integrar todo en webapp.py (Kira, 2 hrs).
- Testing y primeras iteraciones de prompt (Felipe + Kira, 4 hrs).

Entregable: corre python webapp.py y Kitra responde conversacionalmente a cualquier cosa, con memoria de los ultimos turnos, y activa el flujo estricto cuando detecta intencion de agendar.

12.2 Fase B - Calibrar personalidad y conocimiento (Semana 2)

- Recibir dumps de conversaciones reales de WhatsApp (Felipe, 3 hrs).
- Expandir base de conocimiento (FAQ, casos borde, politicas) (Kira + Felipe, 4 hrs).
- Crear test suite con 30-50 conversaciones esperadas (Kira, 3 hrs).
- Iterar prompt en 5-10 rondas hasta que pase >90% de tests (Felipe + Kira, 6 hrs).
- Implementar guardrails (filtro tema, PII, medico) (Kira, 3 hrs).
- Persistencia SQLite + notificaciones al staff (Kira, 3 hrs).

Entregable: bot en simulador que suena humano, evita alucinaciones, notifica al staff cuando alguien agenda.

12.3 Fase C - Conectar a WhatsApp Sandbox (Semana 3)

- Crear cuenta Twilio (Felipe, 30 min).
- Activar Sandbox de WhatsApp (Felipe, 30 min).
- Programar webhook Twilio en FastAPI (Kira, 3 hrs).
- Configurar ngrok para exponer el PC personal (Felipe, 30 min).
- Testing end-to-end con WhatsApp real de Felipe y 2-3 personas de confianza (Felipe, 4 hrs).
- Ajustes por comportamiento en canal real (Kira, 3 hrs).

Entregable: Kitra responde en WhatsApp real via Twilio Sandbox. Cero costo, cero tramite Meta.

12.4 Fase D - Migrar a Meta Cloud API para produccion (Semanas 4-5)

- bullet Iniciar tramites Meta Business (Felipe, 2 hrs iniciales, luego espera).
- bullet Conseguir numero de telefono dedicado (Felipe, 2 hrs).
- bullet Contratar VPS y setup basico (Kira + Felipe, 4 hrs).
- bullet Configurar dominio + SSL (Kira, 2 hrs).
- bullet Programar webhook Meta Cloud API (Kira, 3 hrs).
- bullet Deploy CI/CD desde GitHub (Kira, 3 hrs).
- bullet Monitoreo, alertas, backups (Kira, 4 hrs).
- bullet Esperar aprobacion Meta (3-14 dias, en paralelo).

Entregable: Kitra corriendo 24/7 en VPS, expuesta al numero oficial de KitraDep via Meta Cloud API.

12.5 Fase E - Piloto controlado y hardening (Semana 6)

- bullet Anunciar Kitra a un grupo piloto (pacientes recurrentes, 20-30 personas) (Felipe, 2 hrs).
- bullet Monitoreo intensivo 7 dias: revisar todas las conversaciones (Felipe + Kira, 6 hrs).
- bullet Ajustes finales de prompt y guardrails segun feedback real (Kira, 4 hrs).
- bullet Documentacion final: runbook, manual de operacion, guia para actualizar base de conocimiento (Kira, 3 hrs).

Entregable: Kitra en produccion, con proceso claro para operarla, actualizarla y monitorearla. Proyecto cerrado.

12.6 Fase F (Opcional, Semanas 7+) - Mejoras

- bullet Recordatorios automaticos 24hs antes de la cita.
- bullet Encuesta post-sesion.
- bullet Dashboard interno de metricas (conversaciones, agendamientos, tasas de handoff).
- bullet Integracion con calendario del centro (Google Calendar API).
- bullet Migracion a Postgres si SQLite queda chico.

13. Costos detallados: 1 mes, 3, 6 y 12 meses

Esta seccion desglosa TODOS los costos previsibles, separando setup unico (upfront) y operacion recurrente. Los precios estan en USD y reflejan valores publicos al momento de este documento. Se incluyen escenarios pesimistas y optimistas.

13.1 Supuestos de volumen

Escenario	Conversaciones/dia	Turnos/conversacion	Turnos/mes
Bajo (piloto)	20	6	3.600
Medio (estable)	100	8	24.000
Alto (exito)	300	8	72.000

Un 'turno' es un mensaje del usuario + respuesta del bot. En el escenario medio, el bot procesa ~800 turnos por dia.

13.2 Costo LLM (Gemini 2.0 Flash) por escenario

Precio publico: USD 0.075 por 1M tokens input, USD 0.30 por 1M tokens output. Estimacion tipica por turno: ~1200 tokens input (system prompt + KB + historial) + ~200 tokens output. Costo por turno: ~USD 0.00015.

Escenario	Turnos/mes	Costo LLM/mes	Free tier cubre?
Bajo	3.600	USD 0.54	SI (100% gratis)
Medio	24.000	USD 3.60	Parcialmente
Alto	72.000	USD 10.80	No (paga completo)

Con Gemini Flash el costo del LLM es marginal. Incluso a 300 conversaciones/dia (300 pacientes distintos!), el LLM cuesta menos que una pizza. No es el driver de costo del proyecto.

13.3 Costo mensual comparado por proveedor LLM (escenario medio)

Modelo	USD/mes con 24k turnos	Vs Gemini Flash
Gemini 2.0 Flash	USD 3.60	baseline
GPT-4o-mini	USD 7.20	2x mas caro
Claude Haiku 3.5	USD 43.20	12x mas caro
GPT-4o	USD 132.00	37x mas caro
Llama 3.1 8B local	USD 0	gratis, pero requiere VPS potente ~USD 40/mes

13.4 Costos fijos mensuales (infra + servicios)

Item	Proveedor sugerido	USD/mes
VPS servidor	Hetzner CX11	4.60
Numero WhatsApp Business	Portacion o SIM nueva CL	2.00
Backups	Backblaze B2 (~5 GB)	0.30
Dominio propio	Namecheap (.cl)	1.20 (~USD 14/ano)
Monitoreo uptime	UptimeRobot free	0.00
Monitoreo errores	Sentry free tier	0.00
Email transaccional (opcional)	Resend free 3000/mes	0.00
SUBTOTAL infra		8.10

13.5 Costos WhatsApp (Meta Cloud API)

La categoria de mensaje determina el costo:

Categoria	Ejemplo	Costo Chile
Service (respuesta a chat del usuario dentro de 24h)	Toda la operacion normal del bot	GRATIS ilimitado
Utility (proactivo con proposito claro)	Recordatorio 24h antes de cita	~USD 0.038
Marketing (promocional)	Oferta de packs	~USD 0.058
Authentication (OTP)	Codigos de verificacion	~USD 0.021

Para KitraDep en operacion normal (responder consultas), el costo WhatsApp es **CERO**. Solo empieza a costar si se activan recordatorios masivos o campanas.

13.6 Costo de setup (unico, no se repite)

Concepto	Costo
Registro Meta Business	USD 0
Setup VPS + dominio + SSL	USD 0 (dominio primer ano ~USD 14)
Portacion numero (si aplica)	USD 0-10 segun operador
Codigo del bot (si Felipe lo hace con Kira)	USD 0
Codigo del bot (si contrata un dev freelance)	USD 800-2500 estimados
SETUP TOTAL (con Kira)	USD 0-25
SETUP TOTAL (con freelance)	USD 800-2500

13.7 Proyeccion consolidada: 1, 3, 6 y 12 meses

Todas las cifras asumen escenario **MEDIO** (100 conversaciones/dia, sin campanas de marketing WhatsApp) y Gemini 2.0 Flash como LLM.

13.7.1 Escenario BAJO (piloto, 20 conv/dia)

Concepto	Mes 1	Mes 3 (acum)	Mes 6 (acum)	Mes 12 (acum)
Setup unico	14	14	14	14
Infra fija (USD 8.10/mes)	8.10	24.30	48.60	97.20
LLM Gemini Flash	0 (free tier)	0	0	0
WhatsApp Service	0	0	0	0
TOTAL acumulado (USD)	22.10	38.30	62.60	111.20

13.7.2 Escenario MEDIO (estable, 100 conv/dia)

Concepto	Mes 1	Mes 3 (acum)	Mes 6 (acum)	Mes 12 (acum)
Setup unico	14	14	14	14
Infra fija (USD 8.10/mes)	8.10	24.30	48.60	97.20
LLM Gemini Flash	3.60	10.80	21.60	43.20
WhatsApp Service	0	0	0	0
Recordatorios opcionales (50/dia)	57 (opcional)	171	342	684
TOTAL sin recordatorios (USD)	25.70	49.10	84.20	154.40
TOTAL con recordatorios (USD)	82.70	220.10	426.20	838.40

13.7.3 Escenario ALTO (exito, 300 conv/dia)

Concepto	Mes 1	Mes 3 (acum)	Mes 6 (acum)	Mes 12 (acum)
Setup unico	14	14	14	14
Infra fija VPS mas grande (USD 12/mes)	12	36	72	144
LLM Gemini Flash	10.80	32.40	64.80	129.60
WhatsApp Service	0	0	0	0
Recordatorios (150/dia)	171	513	1026	2052

Concepto	Mes 1	Mes 3 (acum)	Mes 6 (acum)	Mes 12 (acum)
TOTAL sin recordatorios (USD)	36.80	82.40	150.80	287.60
TOTAL con recordatorios (USD)	207.80	595.40	1176.80	2339.60

13.8 Resumen para tomar decision

Para KitraDep escenario tipico (medio, sin campanas de marketing WhatsApp), el costo total del PRIMER AÑO completo es de aproximadamente USD 154. Es decir, ~USD 13 por mes en promedio, todo incluido: LLM, VPS, dominio, backups. El bot literalmente cuesta menos que una suscripcion de streaming.

13.9 Costos NO monetarios que hay que considerar

- Tiempo de Felipe:** ~60-80 hrs repartidas en las 6 semanas de implementacion.
- Tiempo de KitraDep:** ~10-15 hrs para validar prompt, dumps de conversaciones, feedback.
- Tramites Meta:** 3-14 dias de espera sin nada que hacer, solo esperar.
- Mantenimiento post-launch:** ~2-4 hrs/mes revisando conversaciones y ajustando prompt.
- Contingencia legal:** revisar con abogado antes de produccion en salud (~USD 100-300 pago unico).

14. Riesgos, mitigaciones y limites eticos

14.1 Matriz de riesgos

Riesgo	Probabilidad	Impacto	Mitigacion
Bot alucina precio/horario	Media	Alto	Base de conocimiento + prompt estricto + tests
Bot da diagnostico medico	Baja	Muy alto (legal)	Guardrail medico + handoff obligatorio
Costo LLM se dispara	Baja	Medio	Rate limiting + circuit breaker + alertas
VPS cae	Media	Medio	Monitoreo UptimeRobot + auto-restart systemd
Meta rechaza cuenta business	Media	Alto (bloquea produccion)	Documentacion completa desde el inicio + plan B Twilio
Numero WhatsApp baneado	Muy baja con canal oficial	Alto	Usar solo Meta Cloud API o Twilio, nunca no-oficiales
Usuario abusa del bot	Media	Bajo	Rate limiting + bloqueo temporal por numero
Fuga de datos	Baja	Muy alto (legal)	HTTPS + logs enmascarados + backups cifrados
Kira/Google discontinua Gemini	Muy baja	Medio	Abstraccion LLM + facil migrar
Equipo KitraDep no adopta el bot	Media	Alto (proyecto fracasa)	Involucrarlos desde diseno + capacitacion + iterar con feedback

14.2 Limites eticos que el bot NO cruza

Estas son reglas duras codificadas en el prompt y verificadas por guardrails. Son **innegociables**:

bullet **NUNCA** da un diagnostico ni sugiere una causa clinica para un dolor o sintoma.

bullet **NUNCA** recomienda ejercicios o tratamientos por chat.

bullet **NUNCA** promete resultados terapeuticos ni tiempos de recuperacion.

bullet **NUNCA** recomienda medicamentos, ni siquiera OTC.

bullet **NUNCA** dice 'no es grave' o 'no te preocupes' ante un sintoma reportado.

bullet **SIEMPRE** deriva a evaluacion presencial si hay una duda clinica.

bullet **SIEMPRE** reconoce que es un bot al inicio de la conversacion.

14.3 Plan B: que hacer si algo falla en produccion

- 1 **Bot caído:** mensaje automatico 'Estamos con problemas tecnicos, escribinos al numero X'. Se dispara desde monitoreo.
- 2 **Bot alucina en algo serio:** comando PAUSA del admin desactiva el bot y todos los mensajes se derivan a humano.
- 3 **Costo LLM disparado:** circuit breaker corta automaticamente. Admin recibe alerta.
- 4 **Meta suspende cuenta:** se activa fallback a Twilio (ya configurado).

- 5 **Fuga de datos sospechada:** shutdown inmediato + rotacion de credenciales + notificacion legal.

15. Checklist de arranque (que necesita Felipe)

Todo lo que Felipe debe hacer para arrancar el proyecto, agrupado por fase. Los tiempos son estimaciones realistas.

15.1 Antes de escribir la primera linea de codigo

Prep (~2 hrs, se puede hacer en un rato):

- bullet Confirmar con equipo KitraDep que quieren avanzar (buy-in gerencial).
- bullet Definir nombre del bot y personalidad basica (30 min de conversacion interna).
- bullet Recopilar 20-30 chats reales de WhatsApp (con datos borrados o anonimizados).
- bullet Listar los 'nunca' del bot: cosas que NO puede decir.
- bullet Decidir a que numero/WhatsApp deriva cuando pide humano.
- bullet Definir horarios de handoff (o si es 24/7 automatico).

15.2 Cuentas y accesos a crear

- bullet] **Cuenta Google AI Studio** para Gemini API key (5 min, gratis) - <https://aistudio.google.com/>
- bullet **Cuenta Twilio** para Sandbox WhatsApp (15 min, gratis) - <https://www.twilio.com/>
- bullet **Cuenta Meta Business** (30 min inicial + documentacion) - <https://business.facebook.com/>
- bullet **Cuenta Hetzner o DigitalOcean** para VPS (15 min + tarjeta) - <https://www.hetzner.com/>
- bullet **Cuenta Namecheap o similar** para dominio (15 min + tarjeta, ~USD 14/ano)
- bullet] **Cuenta Backblaze B2** para backups (15 min, gratis primeros 10 GB) - <https://www.backblaze.com/b2>
- bullet **Cuenta UptimeRobot** para monitoreo (5 min, gratis)
- bullet **Cuenta Sentry** para errores (5 min, gratis)
- bullet **Repositorio Git privado** (GitHub personal, gratis)

15.3 Documentacion a preparar

- bullet Documento de personalidad de Kitra (1 pagina, plantilla en Anexo A).
- bullet Base de conocimiento inicial (Markdown, plantilla en Anexo B).
- bullet Politica de privacidad publica (1 pagina web).
- bullet RUT y documentos legales del centro para Meta Business.
- bullet Foto de perfil del bot (logo de KitraDep, 640x640 px).

15.4 Presupuesto a aprobar internamente

- bullet Setup unico: USD 14 (dominio primer ano)

- bullet Operacion mensual estimada: USD 13-25
- bullet Contingencia legal (abogado): USD 100-300 (pago unico)
- bullet **Total primer ano estimado: USD 250-450**

15.5 Personas a involucrar

- bullet **Felipe:** product owner + testing + integrador (60-80 hrs)
- bullet **Kira (asistente IA):** programacion + documentacion (asincronico)
- bullet **Equipo KitraDep:** validacion de tono, dumps de chats, feedback (10-15 hrs)
- bullet **Abogado (una consulta):** revisar cumplimiento legal antes de produccion
- bullet **Line derivadora:** punto de handoff, monitorear notificaciones del bot

16. Anexos

Anexo A - Plantilla de personalidad del bot

NOMBRE: Kitra ROL: Asistente virtual de KitraDep, centro de kinesiologia en San Miguel. TONO: Cercano, profesional, empatico. Espanol chileno neutro. FORMALIDAD: Usted por defecto. Tutea si el usuario tutea primero. LONGITUD: Respuestas cortas, 2-4 lineas. Listas si es tecnico. EMOJIS: Uso moderado, maximo 1 por mensaje. NUNCA: - Da diagnosticos medicos. - Recomienda ejercicios o tratamientos. - Promete resultados. - Recomienda medicamentos. SIEMPRE: - Reconoce que es un bot al inicio. - Deriva a evaluacion presencial ante duda clinica. - Recuerda datos ya dados en la conversacion. - Ofrece ayuda concreta y proactiva. HANDOFF: Al WhatsApp de [NOMBRE_KINE_DERIVADORA] +56 9 XXXX XXXX HORARIO HUMANO: Lu-Vi 8-21h, Sab 9-13h. FRUERA DE HORARIO: 'Nuestro equipo humano responde en horario de atencion. Te respondemos ni bien abramos manana!'

Anexo B - Plantilla de fragmento de base de conocimiento

Precios KitraDep (por sesion) ## FONASA (no adherido, valor preferencial) - 1 sesion: CLP \$20.000 - Pack 5: CLP \$100.000 (ahorro: CLP \$0) - Pack 10: CLP \$180.000 (ahorro: CLP \$20.000) **Aclaracion legal:** KitraDep no esta adherido a FONASA. Los valores anteriores son "valor preferencial" que ofrecemos a beneficiarios FONASA. NO se emite bono FONASA ni se descuenta cotizacion. ## ISAPRE (todas) y Particular - 1 sesion: CLP \$25.000 - Pack 5: CLP \$115.000 (ahorro: CLP \$10.000) - Pack 10: CLP \$230.000 (ahorro: CLP \$20.000) Se entrega boleta de honorarios para reembolso en ISAPRE. ## Metodos de pago Efectivo, transferencia, tarjeta debito y credito (POS).

Anexo C - Glosario tecnico

Termino	Definicion
LLM	Large Language Model. Modelo de IA que genera texto (GPT, Gemini, Claude).
Token	Unidad de texto ~4 caracteres. Los LLM cobran por tokens procesados.
System prompt	Instrucciones invisibles que definen personalidad y limites del bot.
Fine-tuning	Reentrenar los pesos del LLM. Complejo y raramente necesario.
RAG	Retrieval-Augmented Generation. Busca fragmentos relevantes antes de generar.
Router	Logica que decide si un mensaje va al flujo o al LLM.
Guardrail	Regla o filtro que impide que el bot haga algo indebido.
Handoff	Derivar la conversacion a una persona real.
Webhook	Endpoint HTTP que recibe eventos de un servicio externo (WhatsApp).
VPS	Virtual Private Server. Servidor virtual barato en la nube.
Meta Cloud API	API oficial de WhatsApp Business, provista por Meta.
Free tier	Nivel gratuito de un servicio en la nube.
Alucinacion	Cuando el LLM inventa informacion falsa con confianza.

Termino	Definicion
Prompt engineering	Arte de escribir instrucciones efectivas para un LLM.

Anexo D - Links utiles

- Google Gemini API docs: <https://ai.google.dev/gemini-api/docs>
- Meta WhatsApp Cloud API: <https://developers.facebook.com/docs/whatsapp/cloud-api>
- Twilio WhatsApp Sandbox: <https://www.twilio.com/docs/whatsapp/sandbox>
- FastAPI docs: <https://fastapi.tiangolo.com/>
- Hetzner cloud: <https://www.hetzner.com/cloud>
- Ley 19.628 Chile: <https://www.bcn.cl/leychile/navegar?idNorma=141599>
- Ley 21.719 Chile (nueva 2024): <https://www.bcn.cl/leychile/navegar?idNorma=1209272>

Anexo E - Contactos del proyecto

Product Owner: Felipe Fierro (KitraDep) Asistente IA: Kira (via Code Puppy) Revisor externo: [NOMBRE DE TU AMIGO] Kine derivadora: [A COMPLETAR] Contacto Meta: Meta Business Help Center Contacto legal: [ABOGADO A DEFINIR]

Fin del documento. Version 1.0. Preparado con dedicacion por Kira para su humano favorito, Felipe.